

## 0.1 期望方差

### 0.1.1 摘要

本期我们主要学习高斯分布的一些性质

### 0.1.2 假设

现在我们有一堆数据:

$$X = (x_1, x_2, \dots, x_N)^T$$
$$x_i \in R^p$$

首先给出我们的模型: 高斯线性模型。

这里我们为了简化起见, 将  $p$  设为 1, 因此

$$x \sim N(\mu, \sigma^2)$$

$$\theta = (\mu, \sigma)$$

接下来我们根据这堆数据, 通过极大似然估计 (MLE) 得出其期望与方差  
下面我们给出似然函数:

$$\begin{aligned} p(X|\theta) &= \log\left(\prod_{i=1}^N \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right)\right) \\ &= \sum_{i=1}^N \log\left(\frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right)\right) \\ &= \sum_{i=1}^N \log\left(\frac{1}{\sqrt{2\pi}}\right) - \log(\sigma) - \frac{(x_i - \mu)^2}{2\sigma^2} \end{aligned}$$

### 0.1.3 期望

下面我们首先使用极大似然估计得出期望  $\mu$  的估计值

$$\begin{aligned} \mu_{MLE} &= \operatorname{argmax}(p(X|\theta)) \\ &= \operatorname{argmin}\left(\sum_{i=1}^N (x_i - \mu)^2\right) \end{aligned}$$

对式子求导得到:

$$\begin{aligned} \sum_{i=1}^N 2(x_i - \mu) &= 0 \\ \sum_{i=1}^N x_i - N\mu &= 0 \\ \mu_{MLE} &= \frac{1}{N} \sum_{i=1}^N x_i \end{aligned}$$

### 0.1.4 方差

同样的，我们使用极大似然估计得出方差  $\sigma$  的估计值

$$\begin{aligned}\sigma_{MLE} &= \operatorname{argmax}(p(X|\theta)) \\ &= \operatorname{argmin}\left(\sum_{i=1}^N \log(\sigma) + \frac{(x_i - \mu)^2}{2\sigma^2}\right)\end{aligned}$$

同样的，我们对式子求导得到：

$$\sum_{i=1}^N \left[ \frac{1}{\sigma} - \frac{(x_i - \mu)^2}{\sigma^3} \right] = 0$$

最后，我们得到估计值：

$$\sigma_{MLE}^2 = \Sigma_{MLE} = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2$$

### 0.1.5 偏置估计

要验证一个估计值是有偏估计还是无偏估计，我们只需计算该估计值的期望即可。

$\mu$

$$\begin{aligned}E[\mu_{MLE}] &= E\left[\frac{1}{N} \sum_{i=1}^N x_i\right] \\ &= \frac{1}{N} \sum_{i=1}^N E[x_i] \\ &= \mu\end{aligned}$$

因此  $\mu_{MLE}$  为无偏估计

$\sigma$

首先我们对  $\sigma$  的估计值进行变形

$$\begin{aligned}\sigma_{MLE}^2 &= \frac{1}{N} \sum_{i=1}^N (x_i - \mu_{MLE})^2 \\&= \frac{1}{N} \sum_{i=1}^N (x_i^2 - 2x_i\mu_{MLE} + \mu_{MLE}^2) \\&= \frac{1}{N} \sum_{i=1}^N x_i^2 - 2\left(\frac{1}{N} \sum_{i=1}^N x_i\right)\mu_{MLE} + \mu_{MLE}^2 \\&= \frac{1}{N} \sum_{i=1}^N x_i^2 - 2\mu_{MLE}^2 + \mu_{MLE}^2 \\&= \frac{1}{N} \sum_{i=1}^N x_i^2 - \mu_{MLE}^2 \\&= \left(\frac{1}{N} \sum_{i=1}^N x_i^2 - \mu^2\right) - (\mu_{MLE}^2 - \mu^2)\end{aligned}$$

令  $f_1 = (\frac{1}{N} \sum_{i=1}^N x_i^2 - \mu^2)$  ,  $f_2 = (\mu_{MLE}^2 - \mu^2)$   
所以:

$$\begin{aligned}E[f_1] &= E\left[\frac{1}{N} \sum_{i=1}^N x_i^2 - \mu^2\right] \\&= E\left[\frac{1}{N} \sum_{i=1}^N (x_i^2 - \mu^2)\right] \\&= \frac{1}{N} \sum_{i=1}^N E[x_i^2] - E[\mu^2] \\&= \frac{1}{N} \sum_{i=1}^N E[x_i^2] - \mu^2 \\&= \frac{1}{N} \sum_{i=1}^N E[x_i^2] - (E[x_i])^2 \\&= \sigma^2\end{aligned}$$

类似的:

$$\begin{aligned} E[f_2] &= E[\mu_{MLE}^2 - \mu^2] \\ &= E[\mu_{MLE}^2 - (E[\mu_{MLE}])^2] \\ &= Var[\mu_{MLE}] \\ &= Var\left[\frac{1}{N} \sum_{i=1}^N x_i\right] \\ &= \frac{1}{N^2} \sum_{i=1}^N Var[x_i] \\ &= \frac{1}{N} \sigma^2 \end{aligned}$$

最后, 将  $f_1$  与  $f_2$  相加, 得到:

$$E[\sigma_{MLE}^2] = \frac{N-1}{N} \sigma^2$$

因此我们通过极大似然估计得到的  $\sigma$  的估计值比真实值略小, 所以为有偏估计而  $\sigma^2$  的无偏估计为  $\frac{1}{N-1} \sum_{i=1}^N (x_i - \mu_{MLE})^2$